

UNIVERSIDAD DE SANTIAGO DE CHILE

FACULTAD DE INGENIERÍA

Departamento de Ingeniería Industrial

PROYECTO INTEGRADOR: REGRESIÓN

Predicción del precio de venta de autos usados

Integrantes del equipo 13:

Fernanda Arroyo
Izaak Ulloa
Rodrigo Olivares
Ana González
María Ignacia Aldana

PROFESOR: Luis Rojo-González, Ph.D.
ASIGNATURA: Estadística Aplicada

SANTIAGO – CHILE
2026

RESUMEN EJECUTIVO

El estudio busca predecir el precio de venta de autos usados a partir de sus características observables, como marca, año, kilometraje, combustible y transmisión. Se compararon modelos lineales, regularizados, GAM y métodos de aprendizaje automático mediante validación cruzada de 5 folds. El GAM fue seleccionado por presentar el menor RMSE de validación (75.608), mejorando en 4,59% al baseline por marca(diferencia dentro del error estándar entre folds). En la evaluación final única sobre test (N=802), obtuvo RMSE de 32.168, MAE de 18.228 y R^2 de 0,638, con una mejora de 20,87% frente al baseline. Se recomienda usarlo solo como apoyo a la tasación, con revisión humana en precios externos y fuera del rango de los datos.

1. Problema, datos y disponibilidad temporal

El objetivo del estudio es desarrollar un modelo de regresión capaz de predecir el precio de un vehículo usado a partir de sus características observables, de modo que pueda servir como apoyo en procesos de tasación o publicación. La unidad de análisis corresponde a cada vehículo registrado en el conjunto de datos y la variable respuesta es `price`. Entre los predictores disponibles se encuentran la marca (`brand`), modelo (`model`), año del modelo (`model_year`), kilometraje (`milage`), tipo de combustible (`fuel_type`), motor (`engine`), transmisión (`transmission`), color exterior (`ext_col`), color interior (`int_col`), historial de accidentes (`accident`) y estado del título (`clean_title`).

Se utiliza el dataset *Used Car Price Prediction Dataset*, publicado en Kaggle por Taeef Najib bajo licencia CC BY 4.0. El archivo contiene 4.009 observaciones y 12 variables. Durante la revisión de calidad se identifican campos vacíos y valores representados mediante guiones en distintas variables categóricas. Estos valores se tratan como faltantes y se reemplazan por la categoría `unknown` para conservar las observaciones, evitando eliminar una cantidad importante de información. A partir del dataset no es posible determinar si el mecanismo de ausencia corresponde a MCAR, MAR o MNAR, por lo que esta condición se reconoce como una limitación.

2. Relaciones e inferencia

Además del objetivo predictivo, se estudia una relación interpretable mediante una regresión lineal múltiple OLS. El modelo utiliza `model_year`, `milage`, `brand`, `fuel_type`, `transmission`, `accident` y `clean_title`, excluyendo las variables de color debido a su elevada cantidad de categorías y al aumento de dimensionalidad que generan.

La relación seleccionada es la del año del vehículo (`model_year`). Manteniendo los demás predictores constantes, cada año adicional de modelo se asocia a un aumento de $984 en el precio (IC 95%: $377 a $1.591; p = 0,0015). Para una diferencia de diez años, el efecto es $9.839 (IC 95%: $3.765 a $15.912), equivalente al 31,9% del precio mediano de entrenamiento.

La significancia estadística no se interpreta por sí sola como relevancia práctica. Por ello, además del valor *p*, se considera la magnitud del cambio respecto del precio típico del

conjunto. Tampoco debe atribuirse causalidad: el coeficiente representa una asociación condicionada a los predictores incluidos en el modelo.El efecto es significativo y de magnitud relevante, pero el intervalo es amplio (entre 12% y 52% del precio mediano para diez años), por lo que la estimación es imprecisa.

Los supuestos de OLS se revisan mediante gráficos de residuos, prueba de Breusch–Pagan para heterocedasticidad, gráfico Q-Q y prueba de Shapiro–Wilk para evaluar normalidad de los residuos, además de VIF/GVIF para revisar multicolinealidad. Estos diagnósticos permiten determinar hasta qué punto las conclusiones inferenciales del modelo lineal son razonables.

3. Validación y preparación

La estrategia de evaluación separa los datos en un conjunto de entrenamiento y uno de prueba mediante una partición aleatoria 80/20 con semilla 123. El conjunto de entrenamiento se utiliza para ajustar y seleccionar los modelos, mientras que el test se reserva para la evaluación final. Esta separación busca evitar seleccionar el modelo utilizando directamente su desempeño sobre las observaciones destinadas a medir generalización.Como el archivo no tiene fechas, la partición es aleatoria y no temporal.

Los datos requieren varias transformaciones antes del modelamiento. Los campos vacíos y guiones de variables categóricas se consideran faltantes y se reemplazan por `unknown`. `price` y `milage` se convierten en valores numéricos eliminando símbolos monetarios, comas y unidades de texto. Para los modelos que utilizan factores se igualan los niveles entre entrenamiento y prueba; cuando en test aparece una categoría no observada en entrenamiento, se utiliza `unknown` cuando está disponible o, en caso contrario, la categoría más frecuente del conjunto de entrenamiento.

La selección de hiperparámetros no utiliza el conjunto de test. Todos los modelos usan los mismos 5 folds, generados con semilla 123 solo con los datos de entrenamiento, de modo que puedan compararse bajo las mismas particiones. El criterio principal de selección es RMSE. Para los modelos implementados con `caret`, el diseño contempla eliminación de predictores con varianza cero, centrado y escalado dentro de cada fold para reducir el riesgo de fuga de información (*data leakage*). OLS y GAM se reajustan en cada fold; en Ridge, Lasso y Elastic-Net, λ se elige con una validación interna dentro de cada fold; averaging y stacking se validan con un esquema anidado (5 folds externos y 3 internos). Los baselines también se calculan solo con las filas de entrenamiento de cada fold.

4. Modelos

Se implementaron distintos modelos de regresión para estimar el precio de los vehículos usados, desde modelos lineales hasta métodos regularizados, modelos aditivos y algoritmos de aprendizaje automático. La selección de configuraciones se realizó mediante validación cruzada, utilizando el RMSE como criterio para los modelos entrenados con `caret`.

Preparación de variables. Para los modelos OLS, Ridge, Lasso, Elastic-Net y GAM se seleccionaron siete variables explicativas: `brand`, `model_year`, `milage`, `fuel_type`,

`transmission`, `accident` y `clean_title`. Se excluyeron `ext_col` e `int_col` debido a su elevada cantidad de categorías, que aumentaba la dimensionalidad y dificultaba el análisis. Las variables categóricas se transformaron en factores. Cuando una categoría aparecía en el conjunto de prueba, pero no en entrenamiento, se reemplazaba por `unknown`, si esta categoría estaba disponible; de lo contrario, se utilizaba la categoría más frecuente del entrenamiento.

Regresión lineal múltiple (OLS). Se construyó un modelo de mínimos cuadrados ordinarios para estimar el precio a partir de las siete variables seleccionadas. Además, se realizaron diagnósticos de residuos mediante gráficos, la prueba de Breusch-Pagan para detectar heterocedasticidad, Shapiro-Wilk para evaluar normalidad, aplicada a una muestra de hasta 5.000 residuos, y VIF/GVIF para examinar la multicolinealidad. También se calcularon intervalos de confianza del 95% para los coeficientes.

Modelos regularizados. Se implementaron Ridge, Lasso y Elastic-Net mediante el paquete `glmnet`. Ridge utiliza una penalización L2, Lasso una penalización L1 y Elastic-Net combina ambas. Estos métodos permiten controlar la magnitud de los coeficientes y reducir el riesgo de sobreajuste; en particular, Lasso puede llevar algunos coeficientes a cero. La regularización se seleccionó mediante validación cruzada de 5 particiones, utilizando el error cuadrático medio (MSE) como criterio y seleccionando el valor de lambda que minimiza dicho error (`lambda.min`). Para Elastic-Net se fijó `alpha = 0.5`, mientras que Ridge utilizó `alpha = 0` y Lasso `alpha = 1`. Los valores de λ elegidos fueron 26.068 (Ridge), 616,4 (Lasso) y 1.629,6 (Elastic-Net); Lasso conservó 62 coeficientes distintos de cero.

Modelo aditivo generalizado (GAM). Se implementó un modelo GAM para representar posibles relaciones no lineales entre el precio y las variables numéricas `model_year` y `milage`, mediante funciones suavizadas con `k = 10`. Las variables categóricas se incorporaron como efectos paramétricos. El modelo se estimó mediante REML. Los grados de libertad efectivos fueron 5,6 para `model_year` y 7,0 para milage, y gam.check no indicó que k fuera insuficiente. También se generaron gráficos de los efectos suavizados y se utilizó `gam.check()` para revisar el diagnóstico del modelo.

Árbol de regresión y modelos de ensamble. Se entrenó un árbol de regresión (`rpart`), probando distintos valores del parámetro de complejidad `cp`: 0.0001, 0.0005, 0.001, 0.005, 0.01 y 0.02. También se implementó Random Forest mediante `ranger`, evaluando distintas combinaciones de `mtry` y `min.node.size`, con la regla de división por varianza y 300 árboles. Para XGBoost se probaron combinaciones de 100 y 300 rondas, profundidades máximas de 3 y 6, y tasas de aprendizaje de 0.05 y 0.1; los demás parámetros se mantuvieron fijos según la grilla definida en el script. Finalmente, se combinaron los tres modelos mediante dos estrategias: *averaging* ponderado, que optimiza los pesos según RMSE, y *stacking*, que utiliza un modelo `glm` como metamodelo.

Selección y evaluación. Los modelos de árbol, Random Forest y XGBoost se ajustaron mediante validación cruzada de cinco particiones sobre el conjunto de entrenamiento, utilizando los mismos folds para facilitar su combinación. La selección de hiperparámetros se basó en el menor RMSE de validación. Los ensambles también utilizaron esos folds. Solo el modelo

ganador por validación cruzada (el GAM) se evaluó en el conjunto de prueba, una única vez, y se comparó con el baseline por marca.

5. Comparación, test y subgrupos

Los modelos se compararon mediante validación cruzada de 5 folds utilizando RMSE, MAE y R^2. El baseline principal fue el promedio por marca, con RMSE = 79.242, MAE = 25.530 y R^2 = 0,106. El GAM obtuvo el menor RMSE (75.608), con MAE = 20.397 y R^2 = 0,187, equivalente a una mejora de 4,59% respecto del baseline. Ridge presentó un desempeño muy cercano (RMSE = 75.709), por lo que la ventaja del GAM debe interpretarse considerando la incertidumbre entre folds. El error estándar del RMSE del GAM fue 17.508. Las diferencias de RMSE entre GAM, Ridge, Elastic-Net, Random Forest, Lasso y OLS (75.608 a 76.646) son mucho menores que el error estándar (17.000 a 18.000), por lo que esos modelos no son estadísticamente distinguibles. El árbol, XGBoost, averaging y stacking quedaron peor que el baseline en RMSE. Se eligió el GAM por su menor RMSE y porque captura relaciones no lineales con pocos parámetros adicionales.

Como análisis de subgrupo se evaluaron los vehículos de año 2020 o posterior. En este segmento, el GAM alcanzó un RMSE de 39.801, frente a 47.181 del baseline por marca, mostrando que la mejora también se mantiene en vehículos recientes. En test, el GAM obtuvo en este subgrupo un RMSE de 41.036 frente a 52.879 del baseline, aunque ese error es mayor que el global (32.168): los autos recientes son más difíciles de predecir.

El conjunto de test permaneció reservado durante la selección y se utilizó una única vez después de elegir el GAM por validación cruzada. Esta evaluación no se empleó para modificar la elección del modelo, evitando seleccionar el sistema a partir de su desempeño en test.

El script actual no calcula intervalos de predicción individuales para nuevas observaciones; por ello, este elemento no se reporta y constituye una limitación del análisis.

6. Interpretación, límites y recomendación

La interpretación de los modelos debe mantenerse en un contexto predictivo y no causal. En OLS, los coeficientes permiten evaluar la dirección y magnitud de las asociaciones condicionadas a las demás variables, junto con sus intervalos de confianza. En particular, `model_year` se utiliza para mostrar una relación interpretable entre antigüedad y precio. El GAM complementa este análisis al permitir que los efectos de `model_year` y `milage` sean no lineales, sin imponer una relación estrictamente recta.

Random Forest se configura para calcular la importancia de variables basada en impureza, lo que permitiría identificar qué predictores intervienen con mayor frecuencia en la reducción del error del bosque. Sin embargo, el script todavía debe extraer y presentar explícitamente dicha importancia.

Una limitación importante corresponde a la extrapolación. Un vehículo con marca, antigüedad, kilometraje o combinación de características poco representadas en los datos puede recibir una predicción menos confiable. Los modelos flexibles y de ensamble pueden capturar relaciones complejas dentro de la muestra, pero ello no garantiza un comportamiento adecuado fuera del rango observado. Además, 3 autos con precio sobre $1 millón concentran gran parte del error: el RMSE de validación (75.608) es casi cuatro veces el MAE (20.397).

También existe un riesgo de *drift*. Al no existir fechas de transacción o publicación, no es posible estudiar directamente si la relación entre características y precio ha cambiado a través del tiempo. En una aplicación real deberían monitorearse periódicamente las métricas de error y la distribución de los predictores, actualizando el modelo cuando se detecten cambios relevantes en el mercado.

En consecuencia, el modelo seleccionado debe utilizarse como una herramienta de apoyo para la tasación y no como una determinación automática del precio final. La recomendación definitiva dependerá de identificar el sistema que supere de manera consistente al baseline, presente un desempeño estable entre subgrupos y mantenga un nivel de error compatible con el uso propuesto.

7. Comparación y resultado final

Tabla 1: Resultados de validación.

Modelo	Familia	RMSE	EE	MAE	R^2	RMSE subgrupo	vs baseline
Baseline	—	79.242	16.520	25.530	0.1064	47.181	— (0.00%)
OLS	Lineal	76.646	17.111	21.060	0.1640	40.825	+3.28%
Ridge/Lasso/EN	Regularizado	75.709	17.893	20.139	0,1843	42.039	4,46%
Splines/GAM	Flexible	75.608	17.508	20.397	0.1865	39.801	+4.59%
Random Forest	Ensemble	76.516	18.015	15.734	0.1668	37.920	+3.44%
Boosting	Ensemble	92.467	21.348	18.669	-0.2168	39.174	-16.69%
Stacking/averaging	Ensemble	95.518	23.167	17.171	−0,2984	34.536	−20,54%

Nota: En las filas agrupadas se reporta el mejor representante del grupo (Ridge; averaging). EE = error estándar del RMSE entre los 5 folds. RMSE subgrupo = autos 2020 o más nuevos.

El modelo seleccionado mediante validación cruzada fue el GAM,ya que presenta el menor RMSE entre todos los candidatos. Se evaluó una única vez sobre el conjunto de test (N=802), sin haber sido ajustado ni reseleccionado con esos datos. Resultado en test:

Etapa	RMSE Baseline	RMSE GAM	Mejora vs baseline
Validación (CV)	79 242,43	75 607,77	+4,59%
Test (N=802)	40 654,33	32 167,77	+20,87%

La mejora se mantiene e incluso se amplía al pasar de validación a test, lo que respalda que la elección del modelo no fue producto de sobreajuste a los folds de validación.

Referencias

[1] Najib, T. (2024). *Used Car Price Prediction Dataset*. Kaggle. https://www.kaggle.com/datasets/taeefnajib/used-car-price-prediction-dataset

A. Diccionario de variables

Variable	Tipo	Unidad / categorías	Ventana	Disponibilidad temporal
`brand`	Categórica	Marca del vehículo	No especificada	Característica observable antes de estimar el precio
`model`	Categórica	Modelo del vehículo	No especificada	Observable antes de estimar el precio
`model_year`	Numérica	Año del modelo	No especificada	Conocido antes de estimar el precio
`milage`	Numérica	Millas	No especificada	Kilometraje acumulado observable al momento de la estimación
`fuel_type`	Categórica	Tipo de combustible	No especificada	Característica observable antes de estimar el precio
`engine`	Categórica	Descripción del motor	No especificada	Característica observable antes de estimar el precio
`transmission`	Categórica	Tipo/descripción de transmisión	No especificada	Característica observable antes de estimar el precio
`ext_col`	Categórica	Color exterior	No especificada	Característica observable antes de estimar el precio

`int_col`	Categórica	Color interior	No especificada	Característica observable antes de estimar el precio
`accident`	Categórica	Historial de accidentes	No especificada	Disponible si el historial es conocido al momento de la estimación
`clean_title`	Categórica	Estado del título	No especificada	Disponible si el estado del título es conocido al momento de la estimación
`price`	Numérica	Precio; moneda no especificada inequívocamente en los datos	No especificada	Variable respuesta; desconocida en el momento de realizar una nueva predicción

B. Reproducibilidad y declaración de IA

El análisis se realizó en R con `used_cars.csv`, utilizando semillas fijas para asegurar reproducibilidad (`set.seed(123)` y semillas determinísticas en validaciones internas). El script ejecuta la partición 80/20, limpieza, validación cruzada de 5 folds, ajuste y comparación de modelos, selección por RMSE y evaluación única en test. Como respaldo genera tablas de validación, resultados finales y diagnósticos de OLS y GAM.

Entre las versiones registradas se encuentran `tidyverse 2.0.0`, `glmnet 5.2`, `mgcv 1.9-4` y `ranger 0.18.0`. Se utilizó ChatGPT y Claude como apoyo para programación(Principalmente para bucles y comandos que salían de lo que se vió en el curso), revisión metodológica y redacción. Los resultados reportados fueron obtenidos y verificados mediante la ejecución del script en R, no generados por IA.