INGENIERÍA INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

PROYECTO INTEGRADOR

REGRESIÓN

Selección de modelo predictivo para predecir precios de automóviles

Fernanda Arroyo, Izaak Ulloa, Rodrigo Olivares, Ana González y María Ignacia Aldana

Estadística Aplicada · Ingeniería Industrial

10 min de exposición | 10 min de preguntas

1. El problema conduce a una decisión

La subestimación o sobreestimación del precio de un vehículo genera pérdidas financieras directas; se requiere un modelo predictivo para respaldar tasaciones precisas en tiempo real.

Problema y usuario

- Contexto y relevancia: Establecer precios de autos usados en forma manual o intuitiva genera alta variabilidad y riesgo financiero para la empresa.
- Usuario: Gerencia de Adquisiciones y Tasadores Comerciales
- Decisión apoyada: Determinar el valor justo de compra a ofrecer a un cliente que entrega su vehículo usado como parte de pago.
- Unidad de análisis: Una transacción individual de un vehículo usado inspeccionado.
- Población objetivo: Transacciones del mercado de vehículos usados comercializados a nivel nacional.

Respuesta y costo

- Respuesta continua: Precio final de venta estimado del vehículo expresado en dólares (USD).
- Instante y horizonte: Momento exacto del peritaje técnico preliminar del vehículo (predicción inmediata previa a la compra).
- Costo de sobre/subestimar:

Sobreestimar el precio: Se paga más por el vehículo, reduciendo el margen o generando pérdidas líquidas al momento de re venderlo.

Subestimar el precio: Se presenta una oferta demasiado baja, perdiendo la retoma frente a competidores.

- Restricción operacional: El modelo debe utilizar únicamente la información disponible en el acta de inspección de recepción del auto.

2. El dataset debe ser pertinente

Se seleccionaron 4.009 registros de transacciones reales en Kaggle, descartando atributos con excesivas categorías para evitar sobrecargar los modelos con variables innecesarias.

Fuente

- Kaggle: Used Car Price Prediction Dataset
- 4.009 observaciones y 12 variables
- Vehículos usados; sin fecha de publicación/venta
- Fuente y licencia: Used Car Price Prediction Dataset bajo licencia CC BY 4.0, disponible en Kaggle (datos públicos de transacciones automotrices).
- Población: Ofertas y transacciones comerciales del mercado automotriz con precios entre $1.599 y $99.999 USD.

Pertinencia

- Marca, año, kilometraje, tipo de combustible, transmisión, accidentes, modelo, título limpio
- Se excluyeron colores por alta cardinalidad
- Disponibilidad al corte: Todas las variables seleccionadas están 100% disponibles al momento en que el tasador examina el auto.

3. EDA e inferencia

El año del vehículo influye significativamente en su precio, pero los supuestos de la regresión lineal se incumplen debido a la variabilidad de los precios en vehículos de alto valor.

Calidad

- Faltantes y guiones se trataron como categoría unknown
- La muestra puede no representar todo el mercado
- Tres autos sobre USD 1 millón influyen mucho en RMSE

Relación estimada

- Año del modelo: +USD 984 por cada año adicional
- IC 95%: USD 377 a 1.591; p = 0,0015
- Asociación ajustada; no implica efecto causal

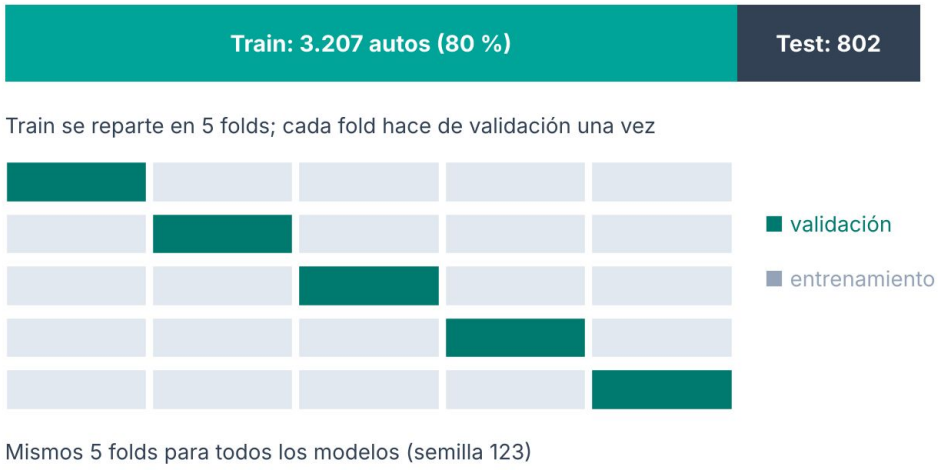
4. La evaluación representa el uso futuro

Dividimos los datos en 80% para entrenar y 20% para evaluación final congelada, aplicando validación cruzada con las mismas particiones para garantizar una comparación transparente.

Partición

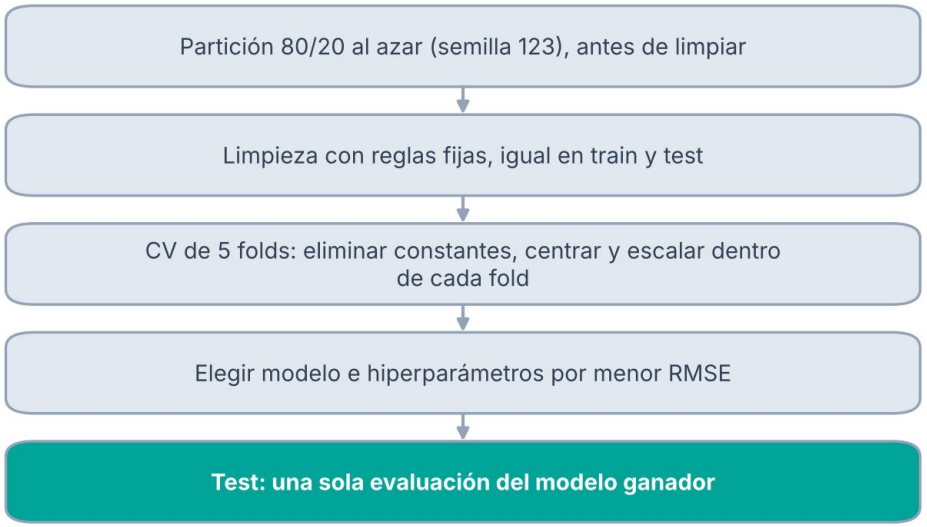
- **80% entrenamiento (3.207) / 20% test (802)**

Partición y validación cruzada (solo train)



CV y preparación

- **5 folds comunes; semilla 123; preprocesamiento dentro de cada fold**



5. Compare familias distintas

Evaluamos 12 configuraciones predictivas de distintas familias, desde regresiones lineales y con penalización, hasta modelos flexibles de curvas y ensambles.

Lineal y regularización

- Regresión Lineal (OLS): Modelo lineal clásico por mínimos cuadrados (línea base paramétrica).
- Ridge, Lasso y Elastic-Net: penalizan coeficientes
- λ controla penalización; α combina L1 y L2

Flexibles y ensembles

- GAM: curvas suaves para año y kilometraje
- Árbol y Random Forest: capturan interacciones/no linealidad
- XGBoost y ensambles: combinación de predicciones

6. Comparar con incertidumbre

El modelo GAM obtuvo el menor error de validación ($RMSE = $75.608 USD), superando a los métodos tradicionales y evitando el sobreajuste de los ensambles complejos.

Métricas

- RMSE: $75.608
- MAE: $20.397
- R^2: 0,187
- Mejora vs. baseline: 4,59%
- RMSE vehículos 2020+: $39.801

Estabilidad

- EE del RMSE: $17.508
- Validación cruzada de 5 folds
- GAM y Ridge mostraron desempeño muy similar
- Ensambles complejos presentaron mayor RMSE y variabilidad
- Selección realizada sin observar el test

	A	B	C	D	E	F	G	H	I
1	Modelo	RMSE	MAE	R2	RMSE_2020_mas	Error_estandar_RMS	Estado	Mejora_vs_baseline_	Elegible
2	GAM	75607.77	20396.68	0.1865	39800.72	17508.06	Calculado	4.59	TRUE
3	Ridge	75709.19	20139.23	0.1843	42039.03	17892.83	Calculado	4.46	TRUE
4	Random Forest	76515.95	15733.52	0.1668	37919.87	18015.45	Calculado	3.44	TRUE
5	Elastic Net	76517.88	20668.77	0.1668	41707.95	17293.93	Calculado	3.44	TRUE
6	Lasso	76607.41	20750.58	0.1648	41308.64	17223.87	Calculado	3.33	TRUE
7	Regresion lineal (OL	76646.22	21059.6	0.164	40825.28	17110.8	Calculado	3.28	TRUE
8	Baseline: promedio	79242.43	25530.37	0.1064	47180.58	16520.45	Calculado	0	TRUE
9	Arbol de regresion	81927.84	22546.03	0.0448	56960.88	19185.2	Calculado	-3.39	TRUE
10	Baseline: promedio	83844.85	30160.62	-4.00E-04	63890.19	17215.85	Calculado	-5.81	TRUE
11	XGBoost	92467.3	18669.26	-0.2168	39173.96	21347.52	Calculado	-16.69	TRUE
12	Averaging	95517.62	17170.77	-0.2984	34535.58	23166.87	Calculado	-20.54	TRUE
13	Stacking	103050.73	18049.28	-0.5113	34171.22	25942.16	Calculado	-30.04	TRUE
14	Baseline: valor previ	138890.21	43366.04	-1.7452	167810.54	33321.86	Calculado	-75.27	FALSE

7. Interpretar el modelo

El kilometraje y el año del vehículo presentan relaciones no lineales con el precio, es decir, sus cambios no siguen una línea recta.

Importancia

- OLS: model_year se asocia a +USD 984 por año, manteniendo constantes las demás variables.
- GAM: model_year (edf = 5,6) y milage (edf = 7,0) se modelan con funciones suavizadas.

Efectos parciales

- PDP e ICE: La curva s(milage)muestra una caída rápida de precio en los primeros 50.000 km. La curva s(model_year) refleja un aumento no lineal acelerado desde el año 2015.
- Cautela causal: Las curvas muestran asociaciones predictivas encontradas por el modelo, no demuestran una causalidad directa.

Cautela

- Son asociaciones predictivas dentro de los datos; no prueban causalidad ni garantizan extrapolación.

8. El test evalúa un sistema congelado

El modelo GAM logró mejores predicciones que el modelo de referencia al evaluarse con datos que no había utilizado anteriormente.

Sistema final

- GAM seleccionado por CV y estimado con REML. Entrenamiento: 3.207 vehículos.
- Mismo preprocesamiento definido en entrenamiento; test se mantuvo apartado.

Test

- GAM en test: RMSE USD 32.168 · MAE USD 18.228 · R^2 = 0,638. No se calcularon intervalos individuales de predicción.
- Baseline por marca: RMSE USD 40.654 · MAE USD 23.558 · R^2 = 0,423. Mejora de RMSE: 20,87%.

	A	B	C	D	E	F	G
1	Modelo	N_test	RMSE	MAE	R2	RMSE_2020_mas	Mejora_vs_baseline_
2	Baseline: promedio p	802	40654.32653	23557.93407	0.4225708847	52878.77326	0
3	Modelo seleccionad	802	32167.76947	18228.05352	0.6384844091	41035.50427	20.87491734

9. Errores y subgrupos

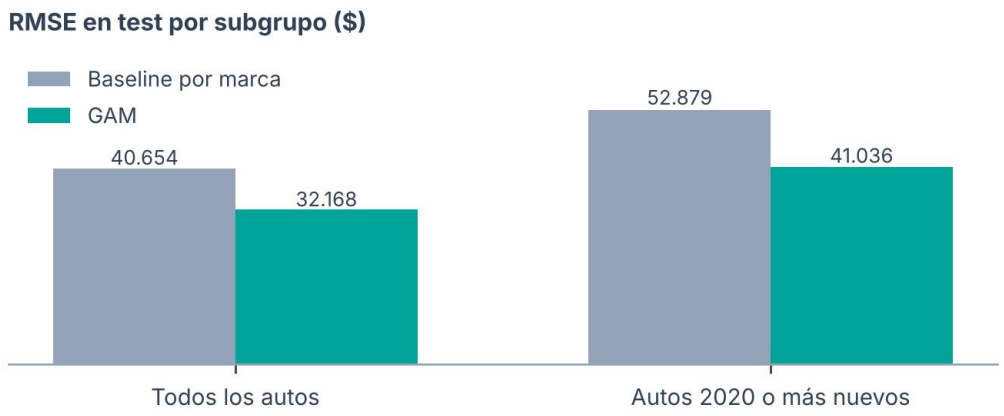
El modelo presenta mayores errores al predecir los precios de vehículos más recientes y de mayor valor.

Residuos

- La dispersión residual crece en vehículos sobre USD 100.000; pocos valores extremos elevan RMSE.
- Tres observaciones sobre USD 1 millón concentran una parte importante del error.

Subgrupo crítico

- Año 2020 o posterior: RMSE GAM = USD 41.036; baseline = USD 52.879 (test).
- El RMSE del subgrupo es 27,5% mayor que el RMSE global (USD 32.168).



10. Recomendación y monitoreo

Se recomienda utilizar GAM para las tasaciones habituales y mantener una revisión manual para los vehículos que presentan mayores dificultades de predicción.

Recomendación

- **Implementar GAM primero como piloto para vehículos dentro del rango bien representado por los datos.**
- **Derivar casos recientes, extremos o fuera de rango a revisión manual. Los cortes 2020+ y USD 80.000 son reglas iniciales a validar, no umbrales demostrados por el estudio.**

Regla de uso propuesta



Monitoreo

- **Monitorear mensualmente MAE/RMSE cuando existan precios reales de cierre; vigilar cambios en los predictores.**
- **Evaluar recalibración periódica. La frecuencia semestral y alerta RMSE > USD 36.000 son propuestas operativas por validar.**

Ciclo de monitoreo





PREGUNTAS Y DEFENSA TÉCNICA

10 minutos | Todos los integrantes deben poder defender datos, código y decisiones

INGENIERÍA INDUSTRIAL · UNIVERSIDAD DE SANTIAGO DE CHILE